


Chat IA reutilizable

Un asistente de consulta, exclusivo de Admin y de solo lectura, desacoplado de Sistema R para poder integrarse después en otros productos.

Decisión central: Hermes no será el backend del producto. Puede vivir en el VPS como agente personal y laboratorio. El componente compartido usará un gateway pequeño, auditable y sin estado.

Arquitectura propuesta



Responsabilidades

- **Widget:** recibe una URL y un token corto; renderiza conversación, fuentes y estados. Nunca conoce claves de proveedor.
- **Gateway:** valida al Admin, limita uso, arma el prompt, registra métricas y llama a OpenRouter.
- **Conector del producto:** obtiene contexto usando la identidad real del usuario. Nunca usa `service_role` para saltar permisos.
- **Proveedor:** OpenRouter queda intercambiable detrás de una interfaz; una lista blanca evita modelos inesperados.

Contrato reutilizable mínimo

`POST /v1/chat` recibe mensajes, identificador de proyecto y token corto. Devuelve texto por streaming, fuentes consultadas, modelo, consumo estimado y un identificador de trazabilidad.

Fronteras que no se negocian

Riesgo	Control inicial
Fuga entre roles o proyectos	JWT validado, <code>tenant_id</code> obligatorio y contexto obtenido con la identidad del usuario.
Prompt injection	El modelo no recibe herramientas de escritura; las fuentes se etiquetan como datos no confiables.
Clave expuesta	<code>OPENROUTER_API_KEY</code> solo en el gateway; rotación independiente por ambiente.
Gasto accidental	Tope duro diario/mensual, máximo de tokens, lista blanca de modelos y límite por Admin.
Datos sensibles en logs	Metadatos mínimos; redacción de prompts y retención corta configurable.
Respuesta inventada	Fuentes visibles, respuesta «no tengo evidencia» y evaluación con preguntas conocidas.

Uso de los USD 10

1. Definir 20–30 preguntas reales con respuesta esperada.
2. Probar dos modelos económicos y uno de referencia.
3. Medir precisión, latencia y coste por conversación.
4. Elegir por evidencia y fijar un presupuesto mensual antes de abrir uso continuo.

¿VPS o función serverless?

Comenzar serverless si el producto solo necesita chat: elimina parches, TLS y disponibilidad de un servidor propio. Usar el VPS de Hostinger para Hermes o para cargas persistentes únicamente cuando exista una necesidad medida.

Hermes: agente personal single-tenant de Marco, útil para experimentar con herramientas y automatizaciones. No comparte memoria, credenciales ni disponibilidad con el widget reutilizable.

Plan de construcción

Fase	Resultado verificable
0 · Contrato	API del gateway, esquema de eventos, presupuesto y conjunto de evaluación; sin conexión a Sistema R.
1 · Prototipo	Widget accesible + gateway + OpenRouter con conversación simple, topes y métricas.
2 · Contexto	Conector de solo lectura para una API de prueba; fuentes visibles y pruebas de aislamiento.
3 · Sistema R	Acceso exclusivo de Admin, contexto autorizado y feature flag; sin herramientas de escritura.
4 · Reutilización	SDK/web component versionado, temas por tokens y adaptador para otro proyecto.

Stack sugerido

- TypeScript; gateway en una función serverless compatible con streaming.
- Interfaz de proveedor propia sobre OpenRouter para cambiar de modelo sin tocar el widget.
- PostgreSQL opcional para conversaciones y métricas; retención desactivable por proyecto.
- Pruebas de contrato, aislamiento, accesibilidad, presupuesto y evaluación de respuestas.

Definition of done de la primera versión

- Solo un Admin autenticado puede abrirla.
- No existe ninguna operación que escriba en el producto.
- La clave del proveedor no aparece en navegador, repositorio ni logs.
- Topes de gasto y modelos permitidos fallan cerrados.
- Cada respuesta distingue evidencia, inferencia y ausencia de datos.
- El widget puede integrarse en un segundo proyecto cambiando configuración, no código central.

Siguiente acción independiente: crear un repositorio propio para el componente, ejecutar la evaluación con los créditos disponibles y conectar Sistema R únicamente después de que su autorización esté validada.